Chapitre 4: Expressions régulières	
INF1070 Utilisation et administration des systèmes informatiques	
Jean Privat & Alexandre Blondin Massé	
Université du Québec à Montréal	
Hiver 2021	
Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 1/58	
Plan	Notes
Introduction	
Expressions régulières de base	
3 Expressions étendues	
2.5.000000 00010000	
Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 2/58	
That a A. Diolium masse (Ogam) Chapite 4: Expessions regulates III 1010 Title 2021 2/30	
	Notes
	Notes
Introduction	

Notes

Expressions régulières	Notes
 Un motif sous forme de chaîne de caractères Qui représente un ensemble (potentiellement infini) de chaînes de caractères 	
Objectifs	
 Identifier du texte ou des parties de texte Chercher dans du texte Transformer du texte 	
Ça ressemble un peu au glob	
J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 4/58	
Rappel: développement des noms de fichiers (glob)	Notes
Désigner simplement un ensemble de fichiers selon un motif	
 Point d'interrogation ? — un caractère quelconque Étoile * — zéro, un ou plusieurs caractères Crochets [] — un seul des caractères de la liste 	
Exemples	
« cat *.txt » se terminent par .txt« cat ?[oa]* » la deuxième lettre est a ou o	
Note Le glob est géré par le shell (pas par la commande) La commande <i>ne voit</i> que les arguments une fois développés 	
Les détails: le manuel de glob	
J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 5/58	
Développement des noms de fichiers (suite)	Notes
Autres motifs permis	
 Point d'exclamation [!] — caractère qui n'est pas dans la liste Intervalles [<debut>-<fin>] — caractère entre <debut> et <fin></fin></debut></fin></debut> 	
Exemple	
 « ls *[!co] » — ne terminent ni par c ni par o « ls [f-i]* » — commencent par f, g, h ou i 	
Entre crochets, les caractères deviennent littéraux	
• « cat [][!?*]* » — commence par], [, !, ? ou *	

Glob \neq expression régulière

Différences

- glob → noms de fichier
- expressions régulières → texte
- Les conventions sont différentes

Extrait du manuel de glob

« Note that wildcard patterns are not regular expressions, although they are a bit similar. First of all, they match filenames, rather than text, and secondly, the conventions are not the same: for example, in a regular expression '*' means zero or more copies of the preceding thing. »

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 7/58

Notes

Qui utilise les expressions régulières ?

Outils de manipulation de texte

- Éditeurs de texte: vi, et tous les éditeurs modernes, ...
- Outils autonomes: grep, sed, ...
- Base de données: MySQL, MariaDB, Oracle, ...

Langages de programmation

- De base en Perl, Python, Java, JavaScript, etc.
- → Opérations sur le texte
- → Vérification et sanitarisation de données

Autres utilisations

- Colorateur syntaxique colorie les mots clés
- Serveur web filtre et transforme des requêtes HTTP
- Compilateur reconnaît les éléments textuels d'un programme

Différentes conventions

De nombreux outils et usages

Font que la syntaxe et les mécanismes varient

- POSIX Basic regular expression (BRE)
- POSIX Extended regular expression (ERE)
- Extensions GNU à POSIX
- Perl compatible regular expression (PCRE)
- Spécificités de chaque langage et outil

Exemple de différences

- Échappement des caractères spéciaux
- Classes de caractères
- Mécanismes plus avancés (lookahead, références relatives, etc.)

Dans le cours: BRE et ERE (POSIX)

Plusieurs commandes les utilisent, notamment grep et sed

Notes			
Notes			
N			
Notes			

La commande grep: rappel	Notes
	Notes
grep — cherche les lignes correspondant à un motif	
• -i,ignore-case ignorer la casse (majuscule/minuscule)	
 -n,line-number affiche le numéro de ligne -v,invert-match afficher les lignes qui ne correspondent pas 	
 -x,line-regexp chercher la ligne entière color colorier le motif (GNU) 	
solar colonia no mesm (ento)	
L Don't A. Black Mars (UDMI) Charles & Empire of Elec-	
J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 10/58	
Autres options utiles de grep • -o,only-match afficher seulement la correspondance (GNU)	Notes
• -1,files-with-matches liste les fichiers qui ont des résultats	
• -c,count compter le nombre de correspondances	
• -A,after-context affiche des ligne de contexte après (GNU)	
-B,before-context affiche des ligne de contexte avant (GNU)	
• -c,context affiche des lignes de contexte autour (GNU)	
• -r,recursive chercher dans des répertoires (GNU)	
• -f,file lire les motifs depuis un fichier	
• -E,extended-regexp passer en mode étendu (on va y revenir)	
 -F,fixed-strings chercher des chaînes fixes (désactive les expressions régulières) 	
• -P,perl-regexp passer en mode PCRE (GNU)	
J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 11/58	
Questions sur grep	
Questions sur grep	Notes
• Combien de mots en français contiennent « tata » ?	
 grep -c tata /usr/share/dict/french Quel mot précède « impact » dans le dictionnaire ? 	
 grep -B 1 impact /usr/share/dict/french Quels dictionnaires ne contiennent pas le mot « immunologie » ? 	
ightarrow grep -L -r immunologie /usr/share/dict/	

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 12/58

	Notes
Expressions régulières de base	
Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 13/58	
Généralités	Notes
 BRE = basic regular expressions Une des versions syntaxiques POSIX (l'autre étant ERE) Reconnue par la plupart des commandes Unix 	
 Reconnue par la plupart des confinances onix Reconnue par plusieurs éditeurs de texte (Vi/Vim, Emacs) Syntaxe de base plus ou moins universelle 	
- Syntaxe de base plus ou mons universene	
Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 14/58	
Caractères littéraux et caractères spéciaux	
caracteres litteraux et caracteres speciaux	Notes
Caractères spéciaux • Le point .	
• Les crochets [et] • L'étoile *	
• Le circonflexe ^ • Le dollar \$	
 La contre-oblique \ Tous les autres caractères sont littéraux 	
« \ » rend littéral un caractère spécial et inversement Attention	
• Certains caractères sont spéciaux pour le shell • BRE \neq glob même s'il y a des caractères communs	

Le point: joker Notes Le point « . » correspond à n'importe quel caractère sauf NUL \$ grep sa.z /usr/share/dict/french ersatz sanza \$ grep anti....../usr/share/dict/french anticonstitutionnellement Note • Équivalent au « ? » en glob • Utiliser « \. » pour reconnaître un point \bullet Certains outils ou options n'incluent pas la fin de ligne dans « . » J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 16/58 L'étoile: répétition Notes L'étoile * indique une répétition d'un motif • 0 fois • 1 fois • ou plusieurs fois \$ cat fruits.txt banane mangue pomme \$ grep -o 'm*e' fruits.txt е mme Note • Protéger l'étoile du shell J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 17/58 Ancrage Notes Deux caractères spéciaux permettent de forcer une position • Le circonflexe « ^ » indique le début de la chaîne (ou ligne) • Le dollar « \$ » indique la fin de la chaîne (ou ligne) \$ grep '^fricas' /usr/share/dict/french fricassée fricassées ${\tt fricasser}$ \$ grep 'key\$' /usr/share/dict/french hockey jockey \$ grep '^mettre\$' /usr/share/dict/french mettre • -x équivaut à ajouter des ^ et \$ implicites Protéger \$ du shell

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 18/58

Question Notes Rechercher tous les mots du français qui contiennent « ${\tt cri}$ » et finissent \$ grep 'cri.*al\$' /usr/share/dict/french cristal scriptural J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 19/58 Crochets : liste de caractères Notes « [] » listent un choix parmi plusieurs caractères \$ echo "mes aieux" | grep -o '[aeiou]*' aieu Note • Protéger « [» et «] » du shell J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 20/58 Crochets : négation de classe Notes • Entre les crochets, • On peut interdire un ou plusieurs caractères • En commençant par le circonflexe « ^ » \$ echo "mes aieux" | grep -o '[^aeiou]*' s x Note • Le circonflexe ^ joue deux rôles (ancrage et négation)

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 21/58

Crochets: intervalles Notes • Entre les crochets, on peut préciser un intervalle • Avec le caractère « - » \$ grep '[x-z][a-c][y-z]' /usr/share/dict/french zézayer \$ grep -o '[x-z][a-c][y-z]' /usr/share/dict/french zay \$ echo '!@#\$%^&-=+()[]' | grep --color '[!-*]' Les intervalles peuvent dépendre • De la *locale* (détails plus tard) • ou du codage (ASCII, Unicode, etc.) man ascii J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 22/58 Classes de caractères POSIX Notes Certains ensembles de caractères sont plus fréquents • [:lower:] : minuscules • [:upper:] : majuscules • [:digit:] : chiffres • [:alpha:] : minuscules et majuscules • [:alnum:] : minuscules, majuscules et chiffres • [:punct:] : ! . ; + # / \ | etc. • [:blank:] : espace et tab • [:space:] : espace, tab, \r, \n, etc. • [:cntrl:] : caractères de contrôle (NUL, BS, ESC, DEL, etc.) • [:graph:] : caractères graphiques, [:alnum:] et [:punct:] • [:print:] : caractères affichables, [:graph:] et espace • [:xdigit:] : caractères hexadécimaux Les classes dépendent de la locale (détails plus tard) J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 23/58 Autres classes de caractères Notes GNU, Perl et de nombreux outils reconnaissent d'autres classes • \w : lettre, chiffre ou souligné « _ » • \₩ : l'inverse de \₩ • \s : un espace • \S : l'inverse de \s • \d : un chiffre (pas GNU) • \D : l'inverse de \d (pas GNU) • \b : frontière entre mot et non-mot • \B : l'inverse de \ъ \< : début de mot • \> : fin de mot En fonction des outils, les classes dépendent (ou non) de la locale

Frontières Notes \$ grep 'garde' /usr/share/dict/french arrière-garde avant-garde [...] sauvegardes sauvegardez \$ grep '\bgarde\b' /usr/share/dict/french arrière-garde avant-garde [...] garde-robe garde-robes J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 25/58 Classes d'équivalence POSIX **Q** Notes • [=c=] : classe d'équivalence du caractère c • Par exemple [=e=] inclut eéèêë \$ grep '[[=e=]][[=e=]]' /usr/share/dict/french agréée agréées créée suppléées Attention aux doubles crochets \$ echo 'e + é = è' | grep -o '[=e=]' Les classes d'équivalence dépendent aussi de la locale J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 26/58 Collations POSIX **Q** Notes • digraphe = 2 caractères qui en forment un seul • Certaines langues ont des digraphes

- ullet Exemple, en tchèque, ch est une lettre entre h et i
- En croate, 1j est une lettre entre 1 et m
- Avant, en allemand, ss était une lettre à part (maintenant β)
- La norme POSIX permet de gérer ces doubles caractères
- Dans le cours, on ne s'en préoccupera pas (pas de problème en français/anglais)

Question	
Rechercher tous les mots du français qui ne contiennent aucune voyelle parmi a, e, i, o, u	Notes
<pre>grep '[^aeiou]' /usr/share/dict/french > reconnaît oiseau à cause du s grep '[^aeiou]*' /usr/share/dict/french > reconnaît tout car * accepte 0 répétitions grep '^[^aeiou]**' /usr/share/dict/french</pre>	
<pre>→ reconnaît âgé à cause des accents grep '^[^aââeéèëiîioôuûü]*\$' fonctionne (même si ù manque) grep '^[^[aa][=e=][=i=][=o=][=u=]]*\$' fonctionne aussi</pre>	
Avec les options de grep	
• grep -x '[^[=a=][=e=][=i=][=o=][=u=]]*' • grep -v '[[=a=][=e=][=i=][=o=][=u=]]'	
J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 28/58	
La commande sed $(1/3)$	
	Notes
sed (stream editor) filtrer et transformer du texte -n mode silencieux	
 -f,file lecture des transformation à partir d'un fichier -i,in-place modifie le fichier (au lieu d'afficher sur stdout) (GNU) -E passer en mode étendu (GNU) 	
posix désactive les extensions GNU (GNU)	
Commandes spécifiques à sed • sed lit une ou plusieurs commandes	
Et les exécutent une à une Par exemple, s/ancien/nouveau/ pour substituer ancien par nouveau	
 Scriptable: on peut les regrouper dans un fichier Nous ne verrons que quelques-unes de ces commandes 	
J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 29 / 58	
La commande sed (2/3)	
24 commands sed (2/0)	Notes
Permet (entre autres) de remplacer un motif par un autre	
<pre>\$ cat form.txt Nom: <nom> Prénom: <prénom></prénom></nom></pre>	
Code permanent: <code> Courriel: <courriel></courriel></code>	
<pre>\$ sed 's/<pre>om>/Alexandre/' form.txt Nom: <nom></nom></pre></pre>	
Prénom: Alexandre Code permanent: <code></code>	
Courriel: <courriel></courriel>	

La commande sed (3/3)Notes \$ cat remplir.sed s/<nom>/Blondin Massé/ s/<prénom>/Alexandre/ s/<code>/BLOA0000000/ s/<courriel>/blondin_masse.alexandre@uqam.ca/ \$ sed -f remplir.sed form.txt Nom: Blondin Massé Prénom: Alexandre Code permanent: BLOA00000000 ${\tt Courriel: blondin_masse.alexandre@uqam.ca}$ J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 31/58 Mythologie de grep Notes Éditeur ed (POSIX) • Développé par Ken Thompson • g/re/p est une commande de ed • globally search the regular expression then print the line Outil grep (POSIX) • Développé comme un outil autonome plus rapide • Popularisé l'utilisation (et la notation) des expressions régulières Dans le dictionnaire: nom et verbe • https://en.oxforddictionaries.com/definition/grep J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 32/58 Notes Expressions étendues

Différences avec BRE Notes Syntaxe différente • Plus de caractères spéciaux • Plus d'opérations Pour l'avoir • grep -E (POSIX), egrep (pas POSIX) • sed -E (GNU) • Par défaut dans de nombreux outils → C'est le défaut quand les gens pensent expressions régulières Note • Certains caractères spéciaux BRE existent sous forme échappée • « (i.|.i){6} » en ERE équivaut à • «\(i.\|.i\)\{6\} » en BRE J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 34/58 Sous-expressions Notes • Les parenthèses « () » forment des groupes • Les opérateurs comme * s'appliquent sur les groupes \$ grep -Ex 'hu(.i)*ent' /usr/share/dict/french huaient huent humidifiaient J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 35/58 Motif optionnel Notes «?» rend un motif optionnel • On peut rendre un caractère optionnel \$ grep -xE 'p?r?is' /usr/share/dict/french pis pris ris • Ou une sous-expression complète \$ grep -Ex 't(rav)?aill((er)?ions)?'\ > /usr/share/dict/french taillerions taillions travaillerions travaillions Question: que trouve « man?g?e?r?i?e?z? » ?

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 36/58

Répétition stricte Notes • L'étoile « * » accepte lorsqu'il y a 0 occurrence \$ grep -xE '(cher)*(as)*' /usr/share/dict/french cher chercher chercheras • Le plus « + » force au moins 1 occurrence \$ grep -xE '(cher)+(as)+' /usr/share/dict/french chercheras J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 37/58 Répétitions d'un nombre précis d'occurrences Notes À l'aide d'accolades « { } » • {m} : exactement m fois • {m,} : m fois ou plus • {,n} : n fois ou moins • {m,n} : entre m et n fois \$ echo 'aaaaaabaabaaa' | grep -oE 'a{5}' aaaaa \$ echo 'aaaaaabaabaaa' | grep -oE 'a{3,4}' aaaa aaa J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 38/58 Questions Notes Quels mots du français ont • un i une lettre sur deux • et au moins trois i? \$ grep -Ex '.?i(.i){2,}.?' /usr/share/dict/french

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 39/58

Répétitions en bref Notes Plusieurs façons de gérer les répétitions • *, {0,} ou {,} : 0, 1 ou plusieurs fois • ?, {0,1} ou {,1} : 0 ou 1 fois • + ou {1,} : 1 fois ou plus • {m} : exactement m fois • {m,n} : entre m et n fois • {m,} : m fois ou plus • {,n} : n fois ou moins J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 40/58 **Avarice** Notes En POSIX, les répétitions ont un comportement avare (greedy) • Elles consomment le plus possible de caractères qui correspondent • Elles trouvent les répétitions les plus longues possibles \$ cat cobal cobalourdeaubobardumbadaududos \$ grep -o 'b.*d' cobal ${\tt balourdeaubobardumbadaudud}$ J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 41/58 Questions d'avarices Notes Seulement les chaînes qui commencent par « b » et finissent par le « d » le plus proche? \$ grep -o 'b[^d]*d' cobal balourd bobard bad Seulement les chaînes qui commencent par « ba » et finissent par le « ud » ou le « rd » le plus proche?

• C'est très difficile... :(

balourd bard

bard badaud

\$ grep -o 'ba[^d]*[ur]d' cobal

\$ grep -o 'ba[^ur]*[ur]d' cobal

Q Anti-avarice Notes PCRE permet le contrôle de l'avarice des répétitions • Une répétition suivie d'un point d'interrogation ? • N'est plus avare L'option -P de grep active le mode PCRE (GNU) \$ grep -oP 'b.*?d' cobal balourd bobard bad \$ grep -oP 'ba.*?[ur]d' cobal balourd bard badaud J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 43/58 Alternance Notes • Équivalent au ou logique ou à l'union ensembliste \$ grep -E 'comberio|ustibi' /usr/share/dict/french combustibilité incomberions incombustibilité succomberions \$ grep -E 'e(cou|pli)(sse|é)\$' /usr/share/dict/french replié replisse secoué secousse J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 44/58 Priorités Notes Il y a une priorité sur les opérateurs \$ grep -Ex 'pro|ton*s?' /usr/share/dict/french " (pro|ton*s? ") Vaut ((pro)|(to(n)*(s)?) ") • Essayer « pro|(ton)*s?» et « (pro|ton)*s?»

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 45/58

Problème

• Qu'en est-il du et logique?

Rechercher tous les mots qui contiennent au moins une fois chaque voyelle a, e, i, o, u.

Quel est le problème de « a.*e.*i.*o.*u » ?

\$ grep a.*e.*i.*o.*u /usr/share/dict/french garde-chiourme gardes-chiourme gardes-chiourmes

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 46/58

Notes

Notes

Solution

Solution simple: utiliser un tube

\$ grep a /usr/share/dict/french | grep e | grep i\ > | grep o | grep u abasourdie abasourdies [...] zygomatiques

- Pas optimal, car relit plusieurs fois chaque ligne
- Mais pas d'autres solutions avec grep
- Il existe des solutions plus puissantes, par exemple Perl (plus tard...)

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 47/58

Capture de sous-chaîne



- On peut réutiliser une ou plusieurs sous-chaîne
- Une sous-chaîne correspond à une sous-expression
- On y réfère avec « \i », où « i » est le numéro de la sous-expression

\$ grep -Ex '(....)..\1' /usr/share/dict/french rentrèrent saisissais sentissent

 $property = -Ex'(...)(...)\2\1''usr/share/dict/french$ entassassent

Notes			

Sous-expressions imbriquées Notes • On peut imbriquer des sous-expressions • Et réutiliser les sous-chaînes associées Question Quels mots ont 2 fois la même paire de lettres répétées ? Exemple: « gouttelette » (deux fois « tt ») $property = E'((.)\2).*\1'/usr/share/dict/french$ Même question mais sans prendre en compte les « ss » et « nn » ? \$ grep -E '(([^sn])\2).*\1' /usr/share/dict/french J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 49/58 Transformations Notes La capture est utile pour les transformations sed • rechercher/remplacer des éditeurs Exemple: Inverser les deux premières lettres de chaque ligne abnaneamngue Pour sed, l'esperluette « & » dénote le motif complet \$ echo "8 chiens 15 chats" | sed -E 's/[0-9]+/*&*/g' *8* chiens *15* chats J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 50 / 58 Question Notes Extraire la partie centrale des mots qui • Commencent par « inter » • Et finissent par « aux ».

• Exemple: « intercontinentaux » \rightarrow « continent »

\$ sed -En 's/^inter(.*)aux\$/\1/p' /usr/share/dict/french

Assertion avant et arrière

PCRE permet de définir des contextes (lookahead, lookbehind)

- (?= assertion positive en avant
- (?<= assertion positive en arrière
- (?! assertion négative en avant
- (?<! assertion négative en arrière

Les assertions ne consomment pas les caractères

\$ grep -Po '(?<=inter).*(?=aux)' /usr/share/dict/french</pre>

Question

Rechercher tous les mots qui contiennent au moins une fois chaque voyelle a, e, i, o, u. (le retour!)

- \$ grep -P '(?=.*a)(?=.*e)(?=.*i)(?=.*o)(?=.*u).*'\
- > /usr/share/dict/french

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 52/58

Q

Notes

Notes

Aller plus loin

On a déjà vu beaucoup de puissance

- POSIX BRE et ERE
- Les extensions GNU
- Un peu de PCRE

PCRE (et d'autres normes)

- Réinitialisation « \K »
- Options de chaînes « (?i) » et cie.
- Sous-chaines nommées
- Référence arrière récursives
- Contrôle de la marche-arrière (backtracking)
- Structures conditionnelles
- → voir la doc PCRE

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 53/58

XKCD



Source: https://xkcd.com/208/ (2007)

Notes			

Limites des expressions régulières

Notes

Notes

Ne permet pas de tout faire

Exemple classique: les constructions récursives ne fonctionnent pas

- HTML, XML
- JSON
- Expression arithmétiques avec des parenthèses

C'est une limite théorique

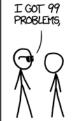
Rapidement illisible

- ^\(?\d{3}\)?[-]*\d{3}[-]*\d{4}\$ \rightarrow numéros de téléphone
- ^M{,4}(CM|CD|D?C{,3})(XC|XL|L?X{,3})(IX|IV|V?I{,3})\$
 - ightarrow nombres romains valides
- ^@%*&+#\$ → sans doute un juron

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 55/58

XKCD









Source: https://xkcd.com/1171/ (2013)

J. Privat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 56/58

Théorie des langages

Expressions régulières

Formellement, une expression régulière est construite à partir

- D'un alphabet et de la chaîne vide
- Des opérateurs de concaténation, d'alternance et de l'étoile de Kleene

Complexité des langages

Plusieurs types de langages formels: Hiérarchie de Chomsky

- Langages réguliers (regular, type 3)
- Langages algébriques (context free, type 2)
- Langages contextuels (context sensitive, type 1)
- Langages généraux (type 0)

Notes			

Comment ça marche ?

Er

• Francisco (c. P.) co (Physic Lead to cate 2. Gate 6. to	
• Expressions régulières utilisent des automates à états finis \rightarrow Très efficaces	
• Les captures et extensions PCRE utilisent des algorithmes récursifs et	
du $backtrack$ $ ightarrow$ Potentiellement très inefficaces	
n savoir plus	
 INF5000: Théorie et construction des compilateurs INF5030: Théorie des automates 	
• INF600E: Création de langages informatiques (Hiver 2020)	
rivat & A. Blondin Massé (UQAM) Chapitre 4: Expressions régulières INF1070 Hiver 2021 58/58	
Chapitre 4: Expressions régulières INF1070 Hiver 2021 58/58	
	Notes
	Netes
	Notes

Notes